輔仁大學統計資訊學系

第二十五屆專題研究成果報告

指導老師：韓南偉

機器學習技術於台股交易策略之應用

學生：張羽晴、吳苡禎、林妏璉

何雨璇、邱詩婷、王思涵、蔡旻汝 撰

中華民國 114 年 11 月

摘　　要

題目：機器學習技術於台股交易策略之應用

校（院）系所組別：輔仁大學管理學院統計資訊學系

學生：張羽晴、吳苡禎、林妏璉、何雨璇、邱詩婷、王思涵、蔡旻汝

指導教授：韓南偉

論文頁數：64

關鍵詞：機器學習、台股、交易策略、XGBoost、技術指標

論文摘要內容：

本研究以 2010 年至 2020 年間台灣加權指數為主要研究對象，探討機器學習於股價市場的應用成效。本研究採用 XGBoost 模型建立交易策略，並與傳統買進持有策略及技術指標交易策略進行比較，透過歷史資料回測績效評估，分析三種策略在報酬率和風險管理方面的差異。

在模型設計上，本研究將開盤價、收盤價、最高價、最低價、成交量、滯後變數以及技術指標等資料作為特徵，並利用移動窗格法進行動態訓練，以反映市場變動特性。XGBoost 模型能學習歷史資料中的價格關聯和趨勢變化，生成買進、賣出及持有訊號，去做實際交易決策。

為了進一步檢驗模型的適用性，除了針對加權指數進行測試外，亦延伸至電子、金融及食品這三種產業類股進行回測。實證結果顯示，XGBoost 模型雖能提升交易績效，但其效果依產業而異，並非普遍優於傳統策略。

Abstract

Title of Thesis：The Application of Machine Learning Techniques in Trading Strategies for the Taiwan Stock Market

Name of Department：Department of Statistics and Information Science, College of Management, Fu Jen Catholic University

Names of Students：Chang Yu Ching、Wu Yi Chen、Lin Wen Lien、Ho Yu Hsuan、Chiu Shih Ting、Wang Si Han、Cai Min Ru

Advisor：Han Nan Wei

Total Pages：64

Key Words：Machine Learning, Taiwan Stock Market, Trading Strategy, XGBoost, Technical Indicators

Abstract：

This study investigates the effectiveness of applying machine learning to the stock market, focusing on the Taiwan Stock Exchange Weighted Index (TAIEX) from 2010 to 2020. The research employs an XGBoost model to establish a trading strategy, comparing it against a traditional buy-and-hold strategy and a technical indicator-based trading strategy. Through performance evaluation based on historical backtesting, the study analyzes the differences among these three strategies regarding returns and risk management.

In terms of model design, this study uses Open, High, Low, Close (OHLC), Volume, lagged variables, and technical indicators as features. It employs a moving window method for dynamic training to reflect market dynamics. The XGBoost model learns price correlations and trend changes from historical data to generate Buy, Sell, and Hold signals for making actual trading decisions.

To further examine the model's applicability, in addition to testing on the TAIEX, backtesting was also extended to three industry sector indices: Electronics, Finance, and Food. The empirical results show that although the XGBoost model can improve trading performance, its effectiveness varies by industry and is not universally superior to traditional strategies.

謝　　辭

專題計畫讓我們有機會將大學階段所學的知識與技能進行實證，並在過程中培養團隊溝通與解決問題的能力。回顧這一年來的研究歷程，雖然過程中充滿挑戰，但也更讓我們對機器學習與統計方法的結合有更深的認識，不論是從資料蒐集，還是模型建構與績效分析，每一個步驟都需要細心與耐心，也考驗我們對知識的運用與邏輯思考能力，透過不斷嘗試、修正錯誤與調整方法，讓我們學會面對未知事物時能保持冷靜，並培養了更強的獨立判斷與解決問題的能力。

在研究過程中，不僅提升我們的專業能力，也讓我們體會到團隊合作與學習氛圍對研究成果的重要性，明白到在學術研究中，知識理論在實務應用上的價值以及意義。

能夠順利完成專題研究並進行成果發表，離不開許多人的支持與幫助，尤其感謝指導教授韓南偉老師在研究過程中給予寶貴建議與鼓勵，提供我們在研究方法與分析思路上不同的角度，並在我們研究陷入瓶頸時耐心給予很多協助，幫助我們釐清問題，使我們在這段期間獲益良多，在每次的討論與指導中，不僅學會更多學術上的知識，也學會如何在面對挑戰時保持專注，教授的指導使得我們對專題的主題與方向更加明確。

此外，也感謝所有成員的努力與配合，在討論、實作與資料分析期間我們互相合作與學習，大家互相分享想法與經驗，營造了積極、互相的學習環境，讓研究過程更加順利與充實。

最後，由衷感謝所有曾經協助與支持完成本次專題計畫的人，因為有大家的幫助，才能讓這段學習歷程得以圓滿完成。透過一年的研究不僅驗證大學生涯所學的知識，更奠定了我們在學術與職涯發展上穩固的基礎。

目錄

第壹章 緒論 1
第一節 研究背景與動機 1
第二節 研究目的 2
第三節 研究流程 3
第四節 甘特圖 4
第貳章 背景知識 5
第一節 機器學習 5
第二節 技術指標定義 6
第三節 績效 9
第參章 文獻探討 15
第一節 XGBoost 15
第二節 量化交易 17
第三節 技術指標 18
第肆章 研究方法 20
第一節 技術指標策略 20
第二節 機器學習策略 21
第三節 操作設定 22
第伍章 實證結果與分析 24
第一節 買進持有策略交易績效 24

第二節 技術指標策略交易績效 26
（一）正確率分析 26
（二）績效分析 28
第三節 機器學習策略交易績效 31
（一）模型評估 31
（二）特徵重要性 33
（三）績效分析 35
第四節 三種策略綜合比較與討論 37
第五節 機器學習應用於個股之交易績效 39
（一）電子類股—以鴻海、建準為例 40
（二）金融類股—以中信金、富邦金為例 42
（三）食品類股—以卜蜂、泰山為例 44
第陸章 結論 48
第一節 研究發現與討論 48
第二節 研究限制與未來建議 49
文獻引用 50
附錄 52

表目錄

表 2-2-1 技術指標三者比較 9
表 5-1-2 買進持有策略績效表 25
表 5-2-3 技術指標訊號準確率比較 27
表 5-2-4 技術指標報酬率 28
表 5-3-5 比較移動窗格 33
表 5-3-6 機器學習與買入持有報酬率 35
表 5-4-7 機器學習、MACD 與買進持有績效比較 37
表 5-5-8 電子股績效比較 41
表 5-5-9 金融股績效比較 43
表 5-5-10 食品股績效比較 45
表 5-5-11 個股績效比較 47

圖目錄

圖 1-3-1 研究流程圖 3

圖 1-4-2 甘特圖 4

圖 4-2-3 移動窗格法 21

圖 5-1-4 買進持有策略於測試期之績效圖 24

圖 5-2-5 技術指標正確率 26

圖 5-2-7 技術指標策略比較 28

圖 5-2-6 MACD 策略於測試期之買賣點標記圖 30

圖 5-3-8 機器模型評估 31

圖 5-3-9 XGBoost 模型之特徵重要性(Feature Importance) 33

圖 5-3-10 機器學習與買入持有累積報酬率比較 35

圖 5-3-11 機器學習策略交易訊號 36

圖 5-4-12 機器學習、MACD 與買進持有累績報酬率比較 37

圖 5-5-13 鴻海 RSI、ML 和買進持有策略之累積報酬率比較 40

圖 5-5-14 建準 RSI、ML 和買進持有策略之累積報酬率比較 40

圖 5-5-15 中信金 RSI、ML 和買進持有策略之累積報酬率比較 42

圖 5-5-16 富邦金 RSI、ML 和買進持有策略之累積報酬率比較 43

圖 5-5-17 卜蜂 RSI、ML 和買進持有策略之累積報酬率比較 44

圖 5-5-18 泰山 MACD、ML 和買進持有策略之累積報酬率比較 45

圖 7-1-19 鴻海之模組分析 52

圖 7-1-20 鴻海技術指標之累積報酬率 53
圖 7-1-21 鴻海之 RSI 交易策略訊號 53
圖 7-1-22 鴻海之 ML 交易策略訊號 53
圖 7-1-23 建準之模組分析 54
圖 7-1-24 建準技術指標之累積報酬率 55
圖 7-1-25 建準之 RSI 交易策略訊號 55
圖 7-1-26 建準之 ML 交易策略訊號 55
圖 7-1-27 中信金之模組分析 56
圖 7-1-28 中信金技術指標之累積報酬率 57
圖 7-1-29 中信金之 RSI 交易策略訊號 57
圖 7-1-30 中信金之 ML 交易策略訊號 57
圖 7-1-31 富邦金之模組分析 58
圖 7-1-32 富邦金技術指標之累積報酬率 59
圖 7-1-33 富邦金之 RSI 交易策略訊號 59
圖 7-1-34 富邦金之 ML 交易策略訊號 59
圖 7-1-35 卜蜂之模組分析 60
圖 7-1-36 卜蜂技術指標之累積報酬率 61
圖 7-1-37 卜蜂之 RSI 交易策略訊號 61
圖 7-1-38 卜蜂之 ML 交易策略訊號 61
圖 7-1-39 泰山之模組分析 62
圖 7-1-40 泰山技術指標之累積報酬率 63

圖 7-1-41 泰山之 MACD 交易策略訊號 63

圖 7-1-42 泰山之 ML 交易策略訊號 63

圖 7-1-43 完整程式碼 QR code 64

第壹章 緒論

第一節　研究背景與動機

隨著科技的快速發展，越來越多投資人轉向量化交易，期望能在瞬息萬變的金融市場中搶占先機，而量化交易透過歷史數據建構策略並進行回測，不僅能節省投資人長時間盯盤的成本，也能降低主觀判斷對決策造成的影響。

根據以往的研究，大部分多著重於提升股票價格預測的準確性，然而，在實際進行股票買賣交易時，如何判斷買賣時點往往比單純預測價格更為關鍵。在判斷股票買進或賣出的時機方面，多數投資人通常會依靠技術指標來制定交易策略，常見的技術指標包括 MACD、KD、RSI 等，並依靠經驗法則來預測買賣時機。

故本報告嘗試將技術指標納入訓練資料，並結合機器學習演算法來制定交易策略，我們選擇使用 XGBoost，因為它在許多資料競賽與實務應用中都證明了其效能，例如 Kaggle 上的許多冠軍隊伍多採取此演算法，且 XGBoost 相較於深度學習或神經網路模型結構相對簡單，同時也具備良好的預測效能與模型解釋能力。透過 XGBoost 直接對股票歷史數據資料進行學習，找出各項資料之間的關聯與模式，並給出買賣訊號，希望藉此驗證是否可利用機器學習優化技術指標的運用方式，而不是只依賴藉由經驗法則所建立的濾嘴。

第二節　研究目的

本報告旨在探索不同投資策略在股票市場中的績效差異，並以買進持有策略、技術指標交易策略與機器學習交易策略三者策略作為比較對象。透過回測與績效分析評估其在報酬率、風險控制與穩定性方面的表現，期望能找出在不同市場下較具優勢的策略，並希望探討以下幾點：

一、　驗證機器學習與技術指標的結合的效益

本研究進一步檢驗將技術指標融入機器學習模型後，是否能提升預測準確度與整體投資績效。藉由比較報酬率、夏普比率及風險控制等指標，評估機器學習與技術指標結合後，是否能展現優於純技術指標策略的表現。

二、　比較不同策略的整體獲利表現

買進持有策略雖然簡單，在市場劇烈波動時，易面臨短期虧損，相較之下；技術指標策略能依據市場變化靈活操作，但容易受到參數設定與假訊號影響。本研究透過回測分析與累積報酬率、夏普比率等指標，比較三種策略之績效表現，以檢驗機器學習交易策略是否能優於買進持有與技術指標交易策略。

第三節　研究流程

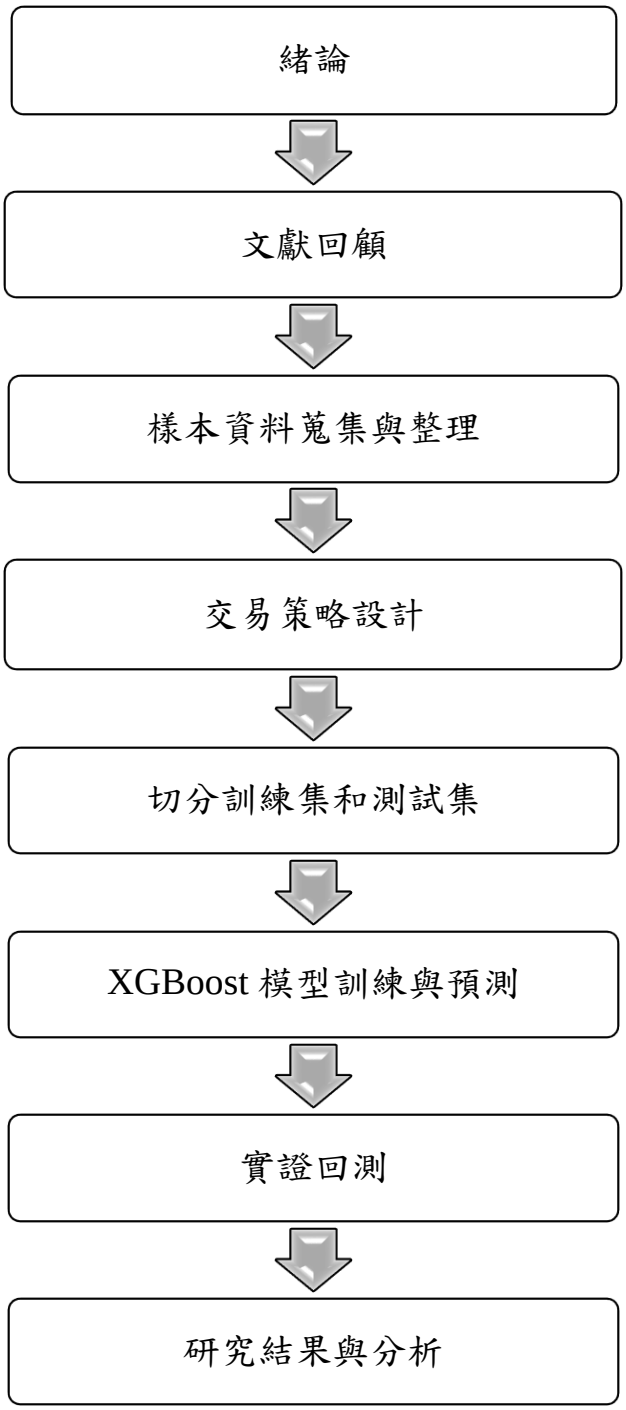

圖 1-3-1 研究流程圖

第四節　甘特圖

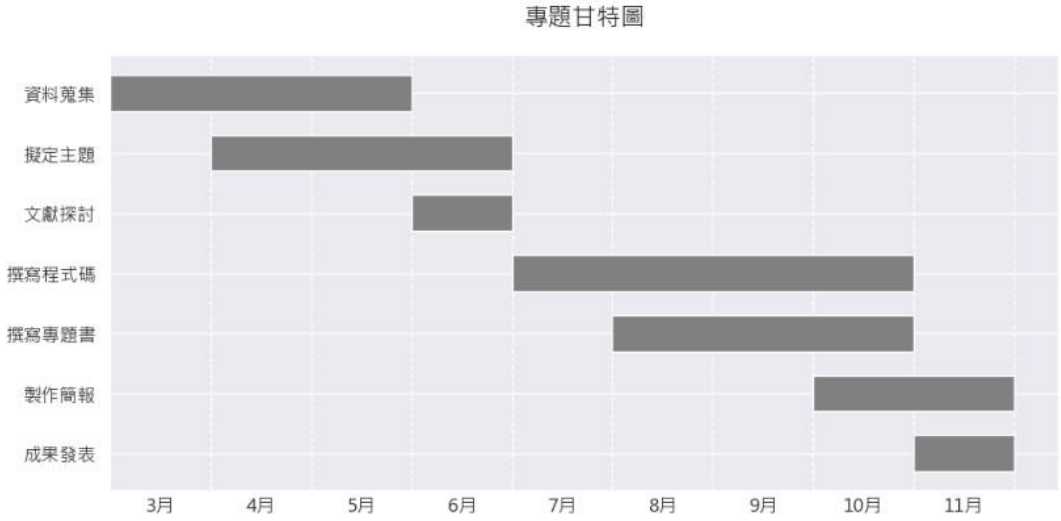

圖 1-4-2 甘特圖

第貳章 背景知識

第一節 機器學習

機器學習（Machine Learning）是人工智慧的一種，顧名思義是讓電腦由過去資料中學習，透過自動化歸納（Automated Induction）去找尋共同點，進而透過自動化演繹（Automated Deduction）進行預測或分類。根據不同的學習方式，可將機器學習分成五大類型：監督式學習、非監督式學習、半監督式學習、強化學習以及自監督式學習。

其中監督式學習是目前在量化交易與金融預測中應用最廣泛的一種方法，本專題所使用的模型即屬於監督式學習。以下為金融預測中常見且具有代表性的監督式學習模型。

本次研究將使用極限梯度提升（XGBoost）作為機器學習的分析工具。極限梯度提升全名為 Extreme Gradient Boosting 是在梯度提升決策樹（GBDT）基礎上的改良與擴展。GBDT 屬於一種加法模型，透過逐步建立多棵決策樹的方式，每一棵新樹的目標是減少前一棵樹預測錯誤（即損失函數梯度），所以後面的樹可以看作是對前面模型預測誤差的校正，最終的預測結果是所有樹的預測結果的加權和，藉此提高整體預測的準確性。

XGBoost 延續了這種逐步修正的架構，還引入了二階導數近似的目標函數設計，並加入正則化項，以控制模型複雜度、避免過擬合。

這些特性使 XGBoost 在處理高維度、非線性關係及大規模數據時具有顯著的優勢，特別適合用於具有變動性高的金融市場預測，相較於其他模型可展現出更高的準確性和穩定性。

第二節　技術指標定義

(一)　RSI（相對強弱指標）：

一種動能指標，用來衡量「近期漲幅與跌幅」的比值，判斷市場是否過熱（超買）或過冷（超賣），數值會介於 0～100 之間，通常以 80 為超買、20 為超賣的分界。若價格與 RSI 方向相反，則可能出現背離，是一種趨勢反轉的訊號。

（一）計算每日價格變動：

$$\Delta P_t = P_t - P_{t-1} \tag{1}$$

（二）分別取出上漲與下跌幅度：

$$Gain_t = \begin{cases} \Delta P_t & ，\Delta P_t > 0 \\ 0 & \end{cases} \tag{2}$$

$$Loss_t = \begin{cases} -\Delta P_t & ，\Delta P_t < 0 \\ 0 & \end{cases} \tag{3}$$

（三）以指數移動平均（EMA）平滑計算平均漲跌幅：

$$\mathrm{EMAGain} = \mathrm{EMA}(\mathrm{Gain}, \mathrm{N}) \tag{4}$$

$$\mathrm{EMALoss} = \mathrm{EMA}(\mathrm{Loss}, \mathrm{N}) \tag{5}$$

（四） 計算相對強度（RS）與 RSI：

$$RS_t = \frac{EMAGain, t}{EMALoss, t} \tag{6}$$

$$RSI_t = 100 - \frac{100}{1 + RS_t} \tag{7}$$

(二) KD（隨機指標）：

一種短線波動型指標，觀察目前收盤價在最近一段時間價格區間內的位置。當 % K 線與 % D 線的交叉可產生黃金交叉與死亡交叉，進一步判斷買賣時機，數值落在 80 以上視為超買，而 20 以下視為超賣，但強勢股可能出現「高檔鈍化」現象。

（一） 計算 RSV（Raw Stochastic Value）：

$$RSV_t = \frac{P_t - L_n}{H_n - L_n} \times 100 \tag{8}$$

- P_t：當期收盤價
- H_n：過去 n 期最高價
- L_n：過去 n 期最低價

（二） 計算 K 與 D 值（以 EMA 平滑）：

$$K_t = EMA(RSV_t, m_1) \tag{9}$$

$$D_t = EMA(K_t, m_2) \tag{10}$$

(三) MACD（移動平均收斂擴散指標）：

一種中期趨勢指標，觀察兩條移動平均線（短期與長期）之間的距離與交叉狀況，當 MACD 線上穿訊號線為黃金交叉、下穿為死亡交叉，也能用柱狀圖觀察動能增強或轉弱以及與價格的背離情況。

（一） 計算快線與慢線的 EMA：

$$EMA_{short,t} = EMA(P_t, 12) \tag{11}$$

$$EMA_{long,t} = EMA(P_t, 26) \tag{12}$$

（二） 計算 MACD 線：

$$MACD_t = EMA_{short,t} - EMA_{long,t} \tag{13}$$

（三） 計算訊號線（Signal Line）：

$$Signal_t = EMA(MACD_t, 9) \tag{14}$$

（四） 計算柱狀圖（Histogram）：

$$Histogram_t = MACD_t - Signal_t \tag{15}$$

三者方法比較：

表 2-2-1 技術指標三者比較

項目	RSI	KD	MACD
類型	力道指標	短期動能指標	趨勢指標
用途重點	判斷超買或超賣	短線轉折點 交叉訊號	中期趨勢 轉強或轉弱
特性	中等靈敏 看背離	變動快 易鈍化	穩定 反應較慢
訊號來源	RSI 數值變化	%K、%D 交叉 與位置	線交叉和 柱狀圖

第三節　績效

績效是指投資在一段期間內的整體表現，反映投資策略是否符合預期及其獲利或虧損情況，是評估交易策略好壞的重要指標。為了檢

驗研究設計的交易策略有效性與穩健性，本節將進行回測分析，透過歷史資料模擬實際投資過程，並比較不同策略在相同市場環境下的表現，評估模型於未來資料上的適用性及風險承受能力選出最佳策略。

在回測過程中，觀察交易策略在不同股票市場的表現差異，藉此評估策略的市場適應性，若策略能維持穩定正報酬，顯示模型具備良好的抗波動與動態調整效果能力；相反地，若策略績效呈現負報酬，則須重新審視模型特徵選擇與交易訊號設定的合理性。我們將採用以下六項指標作為衡量交易策略績效的基準：

(一) 累積報酬率

累積報酬率衡量投資組合從起始日至第 t 日的整體成長倍率，透過投資組合的每日報酬率之計算得出，反映出在整段回測期間的整體表現，包含股票漲跌與現金利息的收益。在本研究中，累積報酬率並非僅追蹤股票價格變動，而是透過「每日投資組合總價值」與「每日報酬率」計算，並進一步計算成「累積報酬率」。

舉例而言，假設初始資金為新台幣 100 萬元，其中 80 萬元投入股票，剩餘 20 萬元存入銀行並產生利息收益（年利率 1 %，換算為日利率 $r_d = (1 + 0.01)^{1/365} - 1$ ）。

若在後續交易日中，投資人判斷某支股票大跌後具有上漲的可能性，再投入額外 10 萬元資金買進該股票，並以每日收盤價計算購買股數，剩餘 10 萬元資金則持續留在現金部位並生息。如此一來，投資組合每日的總價值即隨股票持倉、價格變動與現金部位變化而調整，且其每日投資組合總價值的計算公式如下：

$$V_t = S_t \times P_t^{close} + C_t \tag{16}$$

其中：

- S_t：第 t 日持有股數（會隨買賣訊號與再投資行為變動）
- P_t：第 t 日的股票收盤價
- C_t：第 t 日現金部位（含銀行利息收益）

每日報酬率定義為：

$$R_t = \frac{V_t - V_{t-1}}{V_{t-1}} = \frac{V_t}{V_{t-1}} - 1 \tag{17}$$

累積報酬率定義為：

$$CR_t = \prod_{i=1}^{t}(1 + R_i) \tag{18}$$

其中：

- CR_t：第 t 日的累積報酬率，反映投資組合相對於起始資金的整體成長情況
- R_i：第 i 日的投資組合日報酬率，已整合股票報酬與現金部位利息的貢獻

透過此方式，累積報酬率可完整呈現投資人於不同市場階段的資金配置、加碼與減碼操作對最終投資績效的影響。

(二) 日報酬期望值

期望值衡量投資組合在長期下的平均報酬水準，計算方式為：

$$E[R] = \frac{1}{T}\sum_{t=1}^{T} R_t \tag{19}$$

其中：

- R_t：第 t 日的投資組合報酬率
- T：為回測總交易日數

期望值若為正，表示策略在平均情況下具備正向成長潛力；若為負，則代表該策略在長期可能導致資產縮減。

(三) 日報酬標準差

標準差用以衡量報酬率的波動程度，計算公式為：

$$\sigma_{daily} = \sqrt{\frac{1}{T-1}\sum_{t=1}^{T}(R_t - E[R])^2} \tag{20}$$

其中：

- R_t：為第 t 日的投資組合報酬率
- E[R]：為日報酬期望值

較高的標準差代表報酬率波動大，投資風險相對較高；反之，較低的標準差表示策略績效較為穩定。

(四) 夏普比率（Sharpe Ratio）

用來衡量投資每單位風險下所獲得的超額報酬。此指標可用來比較不同投資方案的風險調整後績效。夏普比率越高，代表在同樣風險下，投資報酬越佳。其計算方式為：

$$Sharpe = \frac{E\left[R_p - R_f\right]}{\sigma_{annual}} \tag{21}$$

其中：

- R_p：為年化報酬率
- R_f：為無風險日利率
- σ_{annual}：為年化標準差

投資人常用夏普率來比較不同資產或基金的表現，夏普率高表示投資人需承受的波動較低，投資人可以參考該指標來選擇風險調整後回報較高的投資標的。

(五) 年化波動率（Annualized Volatility）

用來衡量投資組合一年內的風險水準，其公式為：

$$\sigma_{annual} = \sigma_{daily} \times \sqrt{N} \tag{22}$$

其中：

- σ_{daily}：日報酬標準差
- N：一年中的交易日數（通常取 252）

年化波動率反映投資組合在一年尺度上的報酬不確定性，數值愈高，代表風險愈大。由於年化波動率以報酬率的標準差衡量，無法區分上漲或下跌的方向，因此更適合用來衡量市場或投資策略的「穩定性」，若在此研究中機器學習能產生較低的波動率，則表示投資具有穩定性。

(六) 最大回撤（Maximum Drawdown, MDD）

為衡量策略風險承受能力的指標之一，指的是在特定期間內，投資組合從歷史最高點跌至最低點的最大幅度，其定義公式如下：

$$MDD = \max_{t \in T}\left(\frac{Peak_t - Trough_t}{Peak_t}\right) \tag{23}$$

其中：

- $Peak_t$：投資報酬的最高點
- $Trough_t$：投資報酬高峰後的最低點

最大回撤越小表示投資組合在面臨市場波動時的抗跌能力較強，整體風險較低。即便年化報酬率高，如果最大回撤太大，仍表示該策略在投資過程中承受較高的潛在風險，因此，最大回撤常與夏普比率搭配使用，以全面評估策略的報酬風險。

第參章 文獻探討

第一節 XGBoost

過去的十幾年，機器學習模型逐漸被廣泛應用於金融領域的預測任務中，其中 XGBoost（Extreme Gradient Boosting）演算法成為眾多學者採用的重要工具之一，因具備高準確率、處理高維資料能力強、抗過擬合能力佳與訓練速度快等優勢。許多文獻已證實 XGBoost 在股票、期貨、基金及貴金屬等多種金融商品的預測中皆有良好表現，並且能穩定應對市場波動與複雜變數交互影響所造成的挑戰。綜觀目前相關的研究發現 XGBoost 不僅能有效提升預測精度，而且也具備高度應用彈性與實務價值。

以賴韋勝（2019）為例，他以台灣的股票型基金作為研究對象，採用羅吉斯迴歸、隨機森林、多層感知機與 XGBoost 進行績效預測模型比較。結果指出 XGBoost 在四種模型中表現最為優異，不僅準確率較高，穩定性也明顯優於其他方法。此研究顯示 XGBoost 在面對結構複雜、變數眾多的金融資料時，具備高度的解析能力與實用性。而劉順富（2019）針對台灣加權股票期貨進行漲跌預測與模擬交易分析，他的研究發現 XGBoost 不僅在預測正確率上領先 CART 模型，於平均報酬率、勝率、期望獲利與獲利因子等關鍵交易績效指標亦有顯著優勢，甚至在如金融海嘯等極端市場情境下也能維持正報酬。此外劉妤真（2024）則進一步延伸 XGBoost 應用至多因子選股策略建構，處理 135 個特徵變數，並透過 T 檢定、特徵重要性排序等方法篩選因子進行回測，研究證明 XGBoost 模型在不同時間區間下皆能產出穩健且報酬顯著的投資策略，具備長期預測能力與超額報酬潛力，也說明了 XGBoost 可靈活對應不同變數選擇機制並發揮最佳預測效益。

進一步發現 XGBoost 也展現了在處理市場價格波動預測上之優越性。劉家宏（2023）以台灣小型指數期貨為例，整合成交量、價格與多項技術指標進行模型輸入，並加入負偏度（NCSKEW）與漲跌波動度（DUVOL）等風險衡量變數，進行指數漲跌預測。實證結果顯示 XGBoost 在整體預測準確率及交易績效表現皆優於隨機盲猜策略，尤其在波動性較低的市場情境下，預測準確率更為明顯提升，顯示該模型在穩定市場中更能掌握價格變動趨勢與入場時機。與此研究相似的陳姿妤（2023）使用 2002 年至 2021 年的黃金價格歷史資料，探討 XGBoost 相較於 OLS 與 GARCH 等傳統模型在價格預測表現上的差異。研究中比較了落後一期樣本下各模型的 RMSE，結果發現 XGBoost 的預測準確度高出傳統模型約六成，充分展現其在擷取歷史資訊與時間序列資料解讀方面的能力。此外，該研究進一步指出 XGBoost 具備非線性模式辨識能力，能因應黃金市場價格受多方因素（如經濟、政治、貨幣政策等）交織影響所產生的非穩態波動，預測潛力明顯優於傳統方法。

另一個對 XGBoost 在股價預測方面有力的支持，則來自劉俞含（2018）所進行的跨市場指數預測研究。此研究納入台灣加權股價指數、日經 225 與標準普爾 500 三大股市指數作為預測對象，並選取總體經濟、技術指標與國際股市等三大面向特徵變數，建構 XGBoost、隨機森林、彈性網與整合模型等進行比較。研究結果顯示，XGBoost 在預測台灣加權股價指數時表現最佳，不僅準確率最高，也具有良好的穩定性。在日經 225 與標普 500 的預測中雖未列為最佳，但整體表現仍較其他模型來得穩健，證實 XGBoost 具有跨市場應用的可行性。值得注意的是該研究強調 XGBoost 能有效結合不同來源與性質的特徵資料，並透過內建的特徵重要性排序機制選擇關鍵變數，進一步提升模型解釋力與效能。整體來看，XGBoost 不僅能在單一市場條件下發揮優勢，更具備跨市場、跨資產類別的預測彈性與廣泛應用價值。

第二節　量化交易

量化交易（Quantitative Trading）係指運用數學模型、統計學原理與電腦程式技術所建立之系統化交易方法。此種交易模式透過高速運算與資料分析，對龐大的金融市場資訊進行處理與判斷，將投資理念轉化為具體且可自動執行之買賣策略，其主要優勢在於能有效降低投資決策中之人為主觀判斷，提升決策之效率與精確度。近年來隨著金融市場的環境日益複雜且多變，傳統投資方法逐漸面臨挑戰，為了提升交易策略的效率，眾多學者開始希望能夠透過量化交易技術結合統計方法、機器學習以及深度學習來提升投資績效，並降低投資風險。

其中，黃中義（2020）以台股市場為研究對象，透過 XGBoost 演算法進行模型建置，輔助量化交易中的投資策略，並運用統計方法、機器學習及深度學習建立預測模型，以 RSI、CCI 與 MACD 三種技術指標回測分析 2015 年至 2018 年台股的交易績效，藉此來判斷實證技術分析交易策略在股票市場的獲利。研究結果發現，黃中義使用的 RSI、CCI 以及 MACD 三種技術策略結合機器學習模型能夠有效提升交易策略績效及減少交易次數，證實量化交易可透過機器學習獲得更好的效益。

此外，林柏年（2022）則以美股市場為研究對象，針對類股輪動策略進行量化回測，研究結合價格動能與成交量動能兩種因子，並參考許正諺（2021）及陳正佑（2012）提出的策略進行選股優化，進一步探討不同公司範圍（如羅素 1000、2000 與 3000）與分類層級（Sector 與 Industry）對策略績效之影響。研究結果顯示，動能因子有效提升策略績效，其中大型股為主的羅素 1000 表現最佳，呈現大者恆大、贏者通吃的現象。

而林奕辰（2020）以 2008 年至 2019 年中國市場之指數和股票為樣本，為了改善因複雜的交易市場導致投資人在股票市場中無法依技術指標判斷市場的漲跌，因此林奕辰探討不同機器學習模型（支持向量模型、隨機森林以及人工神經網路）與量化投資的結合，分析在不

同交易期間及量化投資策略的適用性與績效表現。在實證結果中，林奕辰建立模型將數據匯入機器學習模型結合量化策略並進行回測，研究結果指出不同交易期間需要搭配不同交易策略才能獲得最佳績效，表示機器學習與量化交易的結合確實可以讓投資人有效的判斷最佳交易策略。

綜合上述例子可知，無論在台灣、美國或中國等不同國家的股票市場中，量化交易結合機器學習技術皆能有效提升交易策略的績效，並降低投資風險，進一步證實該技術結合在不同市場環境中皆具可行性與實務應用價值，為未來交易策略之發展提供重要參考依據。

第三節　技術指標

過去翁寬晋（2017）以台灣 50（0050）為研究樣本，透過 1 年、3 年、6 年、12 年等不同投資期間，系統性分析移動平均線（MA）、隨機指標（KD）、相對強弱指標（RSI）與指數平滑異同移動平均線（MACD）等四種技術指標所構成的十五種策略組合績效。研究採用變異數分析（ANOVA）檢驗策略間的績效差異，結果顯示 RSI > KD > MACD > MA 的單一指標表現排序。其中最令人矚目的是 RSI 策略在 12 年期內創下 862.56 % 總報酬率、年化報酬率達 20.77 % 遠超過同期大盤表現。另一個重要結論指出「多重指標不保證績效最佳」，四重指標組合績效反而落於中段。這個現象反映了技術分析中的一個重要原則：指標的互補性遠比數量更為重要，過多的指標不僅可能造成訊號衝突，也會增加決策的複雜度，反而降低交易效率。

周一華（2022）探討技術分析之有效性並將研究場域轉向台灣期貨市場，針對 KD、RSI、MACD 及動量指標（MTM）在高槓桿、高波動性環境下的績效表現進行實證。研究結果與翁寬晋高度一致：RSI 單一指標表現最佳，KD 次之，MACD 需與其他指標配合使用。另外周一華研究的一個重要創新是引入「假訊號過濾機制」，即過濾二日內反向訊號的設計。結果顯示，過濾後的策略報酬普遍優於未過

濾情況。這個機制在實務上具有重要價值，因為頻繁的進出場不僅增加交易成本，也容易造成投資人的情緒波動，影響決策品質。

周建維（2011）探討產業別分析策略的比較，其研究期間涵蓋 2006 年至 2010 年，正值全球金融危機前後的劇烈波動期，為驗證技術指標的韌性提供了理想的測試環境。研究以台灣股市九大類股產業指數為標的，如水泥、食品、塑化、紡織、機電、造紙、營建、金融及加權指數，這種產業別的分析方法補足了前兩研究在市場廣度上的不足。在 KD 指標分析方面，周建維特別強調其綜合了動量、移動平均與相對強弱等多重概念的特性。研究發現 KD 指標在波動性較高的類股（如電子、機電）中表現尤為突出，這個發現與前述兩研究的結論相互呼應。從技術分析角度來看，高波動性產業的價格變化較為劇烈，KD 指標的快速反應特性能更有效地捕捉短期轉折訊號，這解釋了為何其在這類產業中表現優異。

三項研究橫跨 2006 年至 2022 年，涵蓋金融危機、市場復甦與平穩發展等不同階段，在現股市場、期貨市場以及產業別分析等多重維度下，RSI 指標始終展現出最穩定的優異表現。KD 指標在三項研究中均位居第二位，特別是在高波動環境下表現突出。MACD 指標的表現則呈現較為複雜的情況需要更精細的情境判斷。然而技術分析並非萬能，投資人仍需結合基本面分析、風險管理等要素，才能在瞬息萬變的金融市場中獲得長期穩定的投資報酬。

第肆章 研究方法

本研究使用台灣經濟新報（TEJ）之台股歷史數據，以台股加權指數作為比較買進持有策略、技術指標交易策略與機器學習交易策略三者績效，並額外觀察三者策略在個股上的表現。

第一節　技術指標策略

在技術指標方面，將 RSI、KD、MACD 三種技術指標做比較，使用三種指標判斷買進賣出。

(一)　RSI

當價格創新低，但 RSI 反而創新高（RSI＞80）時，推斷股價可能反轉向上，因此買入；反之，當價格創新高，RSI 股價創新低（RSI＜20）時，股價可能反轉向下，即賣出

(二)　KD

若出現黃金交叉，表示 K 線由下往上突破 D 線，判斷股價可能上漲（KD > 80）時買入；而若出現死亡交叉，表示 K 線由上往下突破 D 線，判斷股價可能下跌（KD < 20）時賣出

(三)　MACD

同 KD，當出現黃金交叉，表示 DIF 線上穿 Signal 線即買入，出現死亡交叉則賣出

第二節　機器學習策略

採用 XGBoost 建立模型，使用的特徵包含開盤價、收盤價、最高價、最低價與成交量，以及加入和技術指標策略相同的技術指標如 MACD、KD、RSI，但不事先預設規則，而是由 XGBoost 自行學習，找出各項資料之間的關聯與模式。

另外也將前 5 天的所有自變數落後項作為特徵加入模型中，希望可使模型能捕捉時間序列的動態特性，不僅考慮當期的量價資訊，亦能學習過去數日的變化趨勢與自相關特性，提升對未來的預測能力。

模型交易訊號設計如下：

- Buy：未來十日後股價上漲 3 %
- Sell：未來十日後股價下跌 3 %
- Hold：其餘情況

使用資料期間為 2010 年 1 月 1 日至 2020 年 12 月 31 日，以日為交易單位，其中以 2010 年初至 2018 年底的資料作為訓練集，2019 年初至 2020 年底作為測試集，並採用移動窗格法每 20 天重新訓練一次模型。

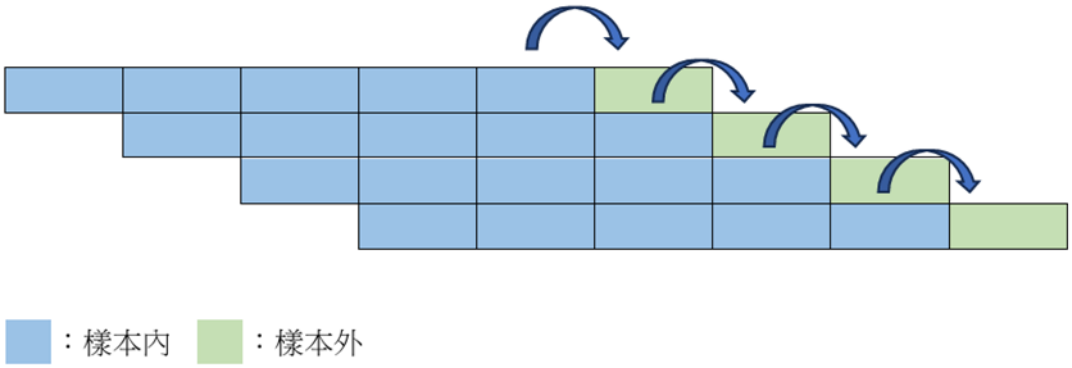

圖 4-2-3 移動窗格法

第三節　操作設定

(一)為簡化計算，暫不考慮手續費及證券交易稅。

(二)期初金額設定為 100 萬元，買進持有策略一開始就將 100 萬投入股市，而機器學習策略和技術指標策略則是將其中 80％ 投入股市，20％ 保留現金並依年利率 1％ 計息。

(三)每次加碼金額為期初金額的 10％，若無現金則不再買入，若無持股則不再賣出。

(四)機器學習策略交易以「訊號隔日開盤價」進行買賣。

買進持有策略其買入股數計算如下：

$$S_t = \frac{1{,}000{,}000}{P_t^{close}} \tag{24}$$

每日總資產價值同公式（16）：

$$V_t = S_t \times P_t^{close} + C_t \tag{25}$$

每日報酬率的計算同公式（17）：

$$R_t = \frac{V_t - V_{t-1}}{V_{t-1}} = \frac{V_t}{V_{t-1}} - 1 \tag{26}$$

以此類推，逐日累積報酬率同公式(18)，即可得出該策略於整個研究期間的累積報酬率。

技術指標策略與機器學習策略其持股數及現金價值之計算如下：

$$S_t = S_{t-1} + \frac{100{,}000}{\text{每日開盤價}} \tag{27}$$

$$C_t = (C_{t-1} - 100{,}000) * (1 + r_d) \tag{28}$$

反之，其賣出後持股數及現金價值之計算如下：

$$S_t = S_{t-1} - \frac{100{,}000}{\text{每日開盤價}} \tag{29}$$

$$C_t = (C_{t-1} + 100{,}000) * (1 + r_d) \tag{30}$$

每日總股票資金為目前擁有的股票資金減掉賣出的 10 萬元股票資金，將 S_t 和 C_t 的計算結果代入公式（25），即可求出當日總資產，在計算每日報酬率時，每日總資產為股票價值加上現金資金，且現金資金以日利率計息，其每日報酬率的計算同公式（26）。

第伍章 實證結果與分析

本研究以台灣加權指數 (TAIEX）及鴻海、建準、中信、富邦、卜蜂、泰山等各股為研究對象，資料取自 TEJ 資料庫。研究期間橫跨 2010 年至 2020 年，並劃分「訓練期」(2010-2018）與「測試期」（2019-2020)，為維持各策略比較之公平性，所有機器學習模型皆以訓練期資料建構，後續所呈現之所有策略績效則以測試期樣本外 (Out-of-Sample) 表現為準。

本章將比較買進持有（B&H)、三種技術指標（KD, RSI, MACD）以及機器學習（XGBoost）策略。績效評估採用累積報酬率、日報酬期望值、日報酬標準差、夏普比率 (Sharpe Ratio)、最大回撤 (Maximum Drawdown, MDD) 及年化波動率等指標。

第一節 買進持有策略交易績效

圖 5-1-4 買進持有策略於測試期之績效圖

表 5-1-2 買進持有策略績效表

買進持有策略	
累積報酬率	46.26%
日報酬期望值	0.09%
日報酬標準差	1.05%
夏普比率	1.28
最大回撤 (MDD)	-28.54%
年化波動率	16.74%

根據圖 5-1-4，買進持有策略在整個回測期間取得了 46.26% 的累積報酬率，從累積報酬率曲線上可見，在 2019 年期間資產淨值雖然經歷了數次震盪，但整體保持上升趨勢，顯示策略在整個期間是盈利的。然而，在 2020 年初，由於疫情影響，報酬率急劇下跌，一度跌破初始資金線，但隨後市場反彈，報酬率恢復增長，此一結果顯示，長期持有能在市場結構回復時重新捕捉上行趨勢，透過時間拉長投資週期來平滑短期波動的影響。日報酬期望值為 0.09%，表示在回測期間內，資產平均每個交易日增加約 0.09%。日報酬標準差為 1.05%，代表單日報酬的變動幅度約為 1% 左右，說明該策略在短期內存在一定波動。

該策略在應對市場極端風險時，策略的淨值曲線出現了急劇且大幅度的下跌，導致其最大回撤達到嚴峻的 -28.54% ，這代表投資者在該期間內，資產曾經歷接近三成的損失，反映了策略對市場沒有任何避險或再平衡的機制，因此市場任何劇烈變動都會直接反映在報酬與淨值曲線上。此外，B&H 策略的年化波動率達到 16.74%，由於投資人在持有期間不做任何調整，報酬隨市場漲跌而變化，當市場上漲時，報酬同步擴大，市場崩跌時，虧損也同時放大，沒有緩衝機制，進一步驗證該策略的資產報酬對市場整體波動的反應程度高。

在風險調整層面，B&H 策略的夏普比率達 1.28，表示在考量報酬與波動後，每承擔一單位風險可獲得 1.28 單位的超額報酬。這表明

B&H 策略作為市場基準，儘管短期內投資者必須承受極大的淨值下跌壓力，但只要能持續持有至市場回升階段，最終仍可獲得可觀的超額報酬。

綜合而言，B&H 策略成功捕捉了整體市場的成長動能，展現其在長期上行趨勢中的報酬潛力。然而，該策略同時暴露於市場系統性風險之下，缺乏防禦性機制，使投資者需具備較高的風險承受能力與長期投資觀，以應對短期劇烈波動與大幅度虧損的挑戰。

第二節　技術指標策略交易績效

(一)　正確率分析

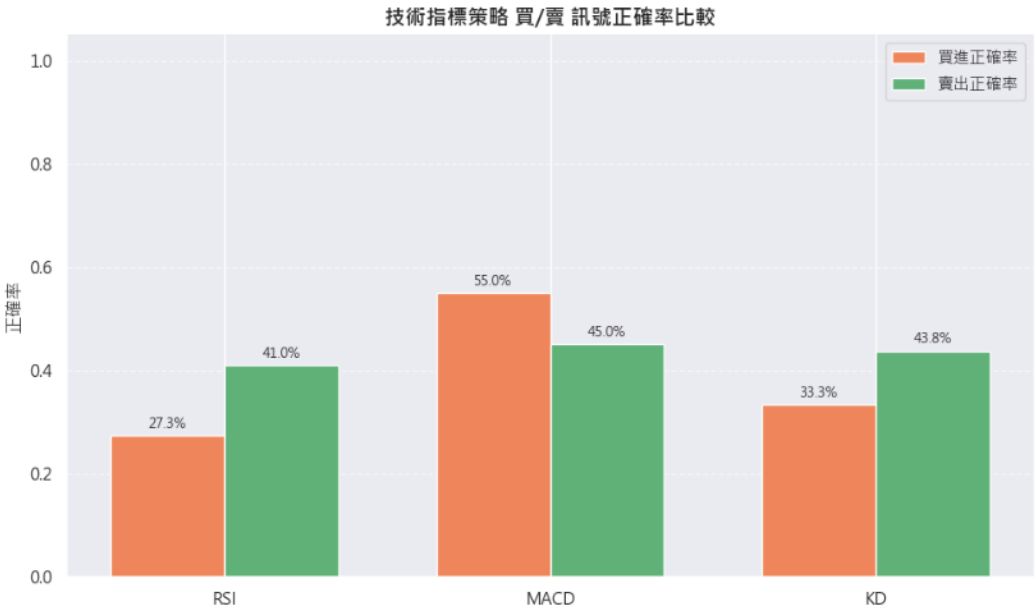

圖 5-2-5 技術指標正確率

表 5-2-3 技術指標訊號準確率比較

策略	買進訊號正確率	賣出訊號正確率	整體正確率
RSI	27.3%	41.0%	38.0%
MACD	55.0%	45.0%	50.0%
KD	33.3%	43.8%	42.1%

在交易正確率方面，KD、RSI、MACD 分別為 42.1%、38.0%、50.0%，顯示 MACD 策略的訊號準確度最高。

綜合比較，三種技術指標中以 MACD 策略的表現最為穩健，其買進與賣出訊號的正確率皆優於另外兩項指標，顯示其具備較高的判斷精準度。

從表 5-2-3 中可以看出，三種技術指標策略在訊號準確率上呈現 MACD 策略的整體準確率最高（50％），KD 為次高（42.1％），RSI 為最次（38 ％）。然而訊號準確率的高低並非決定績效表現的唯一因素，實際績效仍受到策略類型、風險控制與報酬結構等多重因素影響。換言之「勝率」並不等於「獲利能力」，而報酬風險比的管理才是策略成效的核心。

(二) 績效分析

圖 5-2-6 技術指標策略比較

表 5-2-4 技術指標報酬率

	買進持有	RSI	MACD	KD
累積報酬率	46.26%	27.83%	41.96%	14.79%
日報酬期望值	0.09%	0.05%	0.08%	0.03%
日報酬標準差	1.05%	0.41%	0.90%	0.27%
夏普比率	1.28	2.00	1.35	1.68
最大回撤	-28.54%	-6.10%	-24.22%	-3.58%
年化波動率	16.74%	6.47%	14.30%	4.24%

根據表 5-2-4 從三種技術 指標整體累積報酬率來看，MACD 策略以 41.96% 的累積報酬率居首，其次為 RSI 的 27.83%，KD 僅 14.79%，顯示MACD能較有效掌握市場趨勢，捕捉中長期波段的上漲機會；RSI則因進出訊號相對保守，使報酬成長幅度受限；KD則傾向過早出場，導致獲利動能明顯不足。若觀察日報酬期望值，MACD 為

0.08%，略高於 RSI 的 0.05% 與 KD 的 0.03%，進一步印證 MACD 策略在報酬創造能力上具有優勢。

然而，風險控制層面呈現不同結果。RSI 策略的日報酬標準差為 0.41%，遠低於 MACD 的 0.90% 與 KD 的 0.27%，顯示 KD 波動最小、RSI 次之，而 MACD 的短期報酬變動較為劇烈。儘管如此 MACD 的夏普比率為 1.35，在兼顧報酬與波動後仍維持穩定水準，RSI 則以 2.00 的高夏普比率居首，代表風險調整後報酬最為穩健；KD 夏普比率 1.68，介於兩者之間，反映穩定但保守的特性。從最大回撤觀察，KD 的 -3.58% 表現最佳，顯示避險性高；RSI 的 -6.01% 次之，MACD 則達 -24.22%，雖明顯高於前兩者，卻仍顯著低於 B&H 策略的 -28.54%，表示其仍具一定防禦能力。最後就年化波動率而言，KD 最低僅 4.24%，RSI 為 6.47%，MACD 則為 14.30%，顯示 KD 與 RSI 策略的穩定性較高，而 MACD 因反應市場趨勢變化而伴隨較大波動。

由上述結果比較中得知，三種技術指標策略各具特色：RSI 在風險控制與穩定性方面表現突出，適合追求穩健報酬的投資者；KD 雖風險最低，但報酬有限，屬於防禦型策略；MACD 則在兼顧報酬與可接受風險的條件下展現最佳的整體績效。與 B&H 相比，MACD 在報酬率上接近市場整體表現，卻能有效降低極端虧損幅度，展現策略的靈活性與趨勢追蹤優勢。綜合所有指標，MACD 策略在報酬潛力、風險控制及市場適應性三方面取得平衡，為本研究中綜合績效最佳的技術指標策略。

圖 5-2-7 MACD 策略於測試期之買賣點標記圖

為具體展示技術指標的交易訊號，圖 5-3 以表現最佳的 MACD 策略為例，標示了其在測試期間的買賣點。至於 RSI 與 KD 策略的買賣點圖，則詳見附錄。

從圖中可清楚觀察到 MACD 策略的交易行為，並印證了其 45.0 %的賣出訊號正確率和 55.0 %的買進訊號正確率。該策略在市場處於明顯上漲趨勢時，發出的買進訊號多出現在趨勢的初期或中期，並於價格接近高點前產生賣出訊號，有效地追蹤了市場趨勢並鎖定利潤。此結果亦反映了 MACD 策略作為典型趨勢追隨指標的應用特性，也是其累積報酬率 (41.96 %) 僅次於 B&H 策略的原因。

第三節　機器學習策略交易績效

(一)　模型評估

本節評估的機器學習模型（XGBoost）使用 2010-2018 年之訓練期資料進行建構。為評估其泛化能力，我們使用 2019-2020 年的測試期資料來檢驗其預測成效。

```
--- ML 模型分類報告 ---
Classification Report:
              precision    recall  f1-score   support

           0       0.69      0.85      0.76       323
           1       0.35      0.11      0.17       105
           2       0.14      0.12      0.13        49

    accuracy                           0.61       477
   macro avg       0.39      0.36      0.35       477
weighted avg       0.56      0.61      0.57       477
```

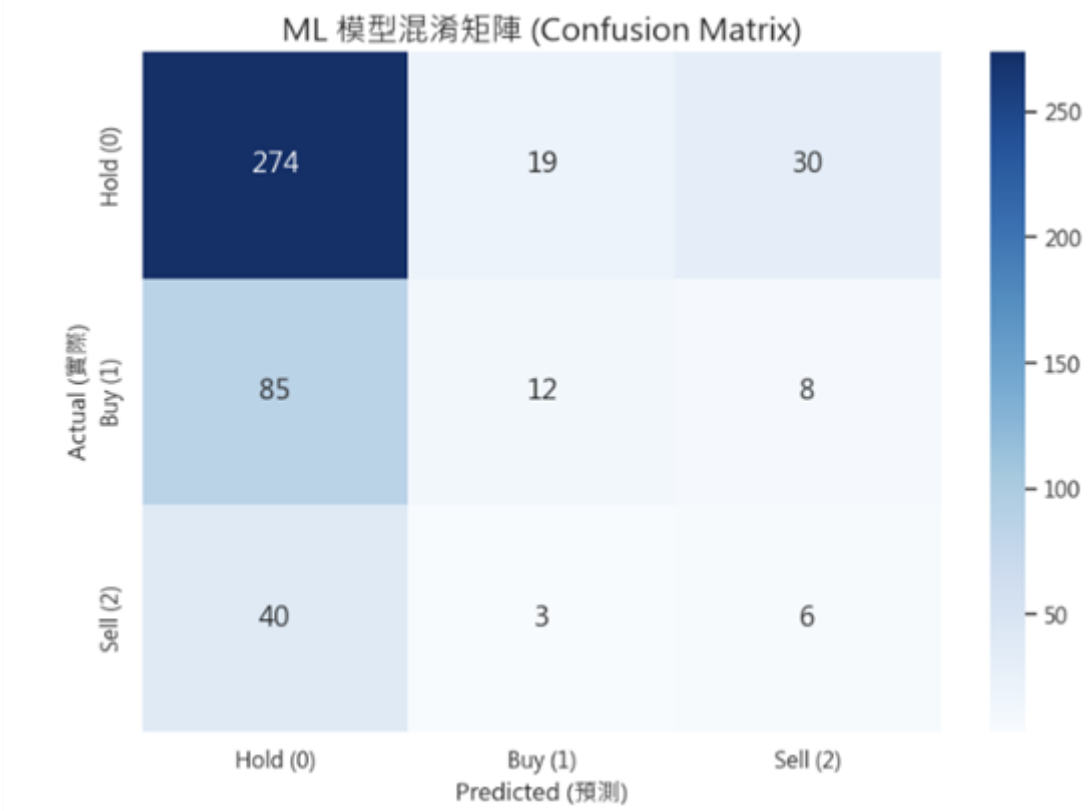

圖 5-3-8 機器模型評估

圖 5-3-8 呈現了模型在測試期數據上的混淆矩陣，圖 5-4-9 則彙整了其分類報告。圖上呈現了 ML 模型的分類報告與混淆矩陣，用以呈現模型在「持有（0）、買進（1）、賣出（2）」三類交易訊號上的預測準確度。

根據分類報告，模型之準確率（Accuracy）為 61%，但因為這三個類別的分佈極度不平衡，導致準確率存在嚴重的誤導，單獨看準確率會無法真實反映模型的鑑別能力。因此從宏觀平均指標 (Macro Avg) 來看，F1-score 為 0.35，僅優於以等機率隨機猜測（約 33.3%），代表模型在整體的表現有待加強。

就各類別表現而言，模型對「持有」訊號之預測最為可靠，召回率（Recall）達 0.85，表示約 85% 的實際持有情況能被模型正確辨識，突顯出模型偏向保守、擅長維持既有部位的特性。

相對地，模型在辨識「買進」與「賣出」訊號上表現較弱，對於「買進」訊號，精確率（Precision）為 35%、召回率為 11%、F1-score 為 17 %，意味著當模型發出買進訊號時僅有約 35%為真實上漲，且模型僅正確檢測出的實際上漲機會佔全部上漲之 11%（即錯失了約 89% 的買進機會）；對於「賣出」訊號，精確率為 14%、召回率為 12%、F1-score 為 13%，顯示賣出訊號之可靠度極低，且大多數實際應賣出情況未被模型偵測到。這代表模型在市場劇烈變動或趨勢反轉時，對於訊號變化的反應較不敏感，導致延遲布局或錯失停損時機，這樣的預測特性也驗證了模型偏向保守判斷，正確維持持有部位的能力較好，但對市場反轉訊號的敏感度仍需提升。

為了進一步了解移動窗格法對模型預測表現的影響，於是在其他變數條件不變的情況下，將目前使用的模型與未使用移動窗格法進行簡單的比較。

表 5-3-5 比較移動窗格

	說明	正確率
未使用移動窗格	一次性訓練	0.49
使用移動窗格	滾動訓練	0.61

在模型訓練策略的比較上，未使用移動窗格法的預測正確率為 0.49；而採用移動窗格法後，正確率提升至 0.61。此結果顯示，透過移動窗格法動態更新訓練資料，能有效反映市場隨時間變化的特性。

(二) 特徵重要性

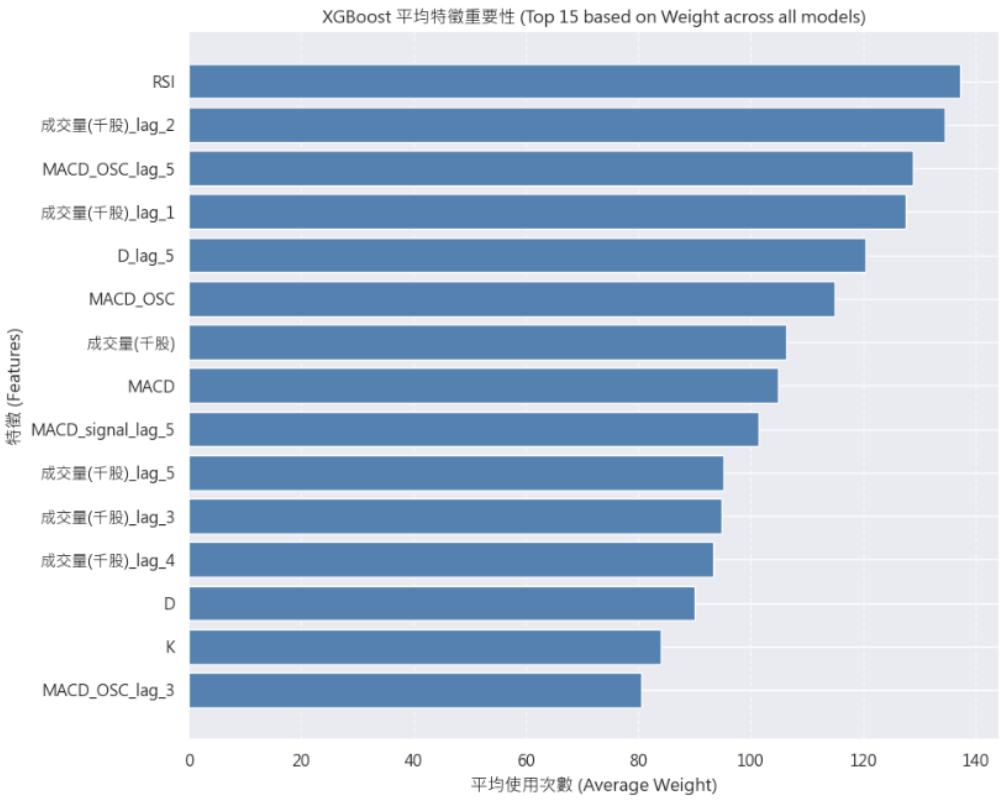

圖 5-3-9 XGBoost 模型之特徵重要性(Feature Importance)

圖 5-3-9 展示了 XGBoost 模型在市場預測時所依賴的前 15 關鍵特徵，其排序清晰揭示了模型判斷市場走向時的核心依據，模型的核心邏輯高度依賴動能、量能，以及時間序列上的延遲資訊。

動能指標在模型中佔據了重要地位。根據特徵重要性排序結果，RSI（相對強弱指標）在所有特徵中具有最高的平均重要性，顯示市場當前的買賣力道與超買超賣動能，是模型判斷趨勢方向時的主要依據之一，其數值高低直接指示了市場可能的回跌或反彈。同時，多個 MACD 相關指標（如 MACD_OSC_lag_5、MACD_OSC 和 MACD）以及 KD 指標（D 線和 K 線）也穩居前列，這些指標的組合使得模型能夠在捕捉短線動能反轉點與中長期趨勢延續性之間尋找平衡。

此外，成交量作為趨勢有效性的主判斷依據，在 Top 15 中佔據了多達六個席位，這強烈暗示了市場資金是否「認同」價格方向，是模型判斷趨勢能否延續的關鍵。這些量能特徵，特別是成交量(千股)_lag_2 和 lag_1 等滯後變數，證明模型比單純觀察價格更依賴流動性變化，傾向於量先價行的預測邏輯。同時，多個 lag（滯後）特徵的存在，也說明 XGBoost 模型擅長從歷史序列中找尋交互與非線性模式，使其能捕捉到延遲性趨勢和已構成的條件，藉此提前嗅到變盤的可能性。

總體而言，這組特徵說明了模型的核心邏輯為：「量先價行 ＋ 動能轉折」，即市場趨勢的延續性最為關鍵。模型會綜合評估動能指標、量能變化，並結合歷史序列的條件，來判斷當前的趨勢是加速、假突破，還是籌碼換手的轉向訊號。因此，這組特徵構建的預測模型能夠在動能指標的協助下抓反轉，並透過成交量來確認趨勢的有效性，從而提升預測勝率。

(三) 績效分析

圖 5-3-10 機器學習與買入持有累積報酬率比較

表 5-3-6 機器學習與買入持有報酬率

	買進持有	機器學習策略
累積報酬率	46.26%	54.72%
日報酬期望值	0.09%	0.10%
日報酬標準差	1.05%	0.68%
夏普比率	1.28	2.35
最大回撤	-28.54%	-5.84%
年化波動率	16.74%	10.75%

從累積報酬率比較圖中可清晰觀察到，在整個回測期間，機器學習策略（ML） 的表現優於買進持有策略（B&H），尤其在風險控制和效率方面展現出壓倒性優勢。在整體回報方面，ML 策略成功克服市場波動，最終取得了 54.72% 的累積報酬率，不僅高於 B&H 策略的 46.26%，也提供了較高的日報酬期望值。在風險控制上，B&H 策略的最大回撤（MDD）高達-28.54%，而 ML 策略的 MDD 僅達到 -5.84%，成功將虧損風險降低了近五倍，同時，ML 策略的年化波動率

（10.75%）和日報酬標準差（0.68%）均遠低於 B&H 策略，體現了更高的穩定性。

這種高效益、低風險的結合，使 ML 策略在風險調整後報酬方面大幅領先。ML 策略的夏普比率高達 2.35，遠優於 B&H 策略的 1.28，這表明 ML 策略能夠以更少的波動性風險，獲取更高的超額報酬，展現出極佳的績效。

綜觀圖表，在 2020 年初市場崩跌期間，B&H 策略的報酬率曲線出現明顯且急劇的下滑，而 ML 策略雖同樣受到短期衝擊，但其資產淨值於短時間內即迅速回升，展現出良好的恢復能力與市場適應性。此現象顯示，ML 策略雖未完全避開市場下跌風險，卻能在震盪後快速修復損失，展現其兼具穩定性與韌性的優勢特徵。

圖 5-3-11 機器學習策略交易訊號

圖 5-3-11 提供了 ML 策略在測試期間的實際買賣點。在 2019 年末，模型觸發了密集的賣出訊號，多次在短線高點附近賣出，導致無法享受到完整的上漲報酬，年底報酬率出現橫盤。面對 2020 年初的疫情崩盤，急遽下跌時產生部分賣出訊號，並能在市場低谷適時生成買進訊號，隨著市場進入多頭格局，策略的累積報酬率隨之增加。總之，ML 策略的超額報酬主要來自於對反彈與多頭行情中趨勢的識別

能力。

第四節　三種策略綜合比較與討論

圖 5-4-12 機器學習、MACD 與買進持有累績報酬率比較

表 5-4-7 機器學習、MACD 與買進持有績效比較

	買進持有	機器學習	MACD
累積報酬率	46.26%	54.72%	41.96%
日報酬期望值	0.09%	0.10%	0.08%
日報酬標準差	1.05%	0.68%	0.90%
夏普比率	1.28	2.35	1.35
最大回撤	-28.54%	-5.84%	-24.22%
年化波動率	16.74%	10.75%	14.30%

為進行最終的綜合評估，本節將 B&H 策略、MACD 策略，以及 ML 策略進行並列比較。圖 5-4-12 與表 5-4-7 彙整了三種策略在測試期 (2019-2020) 的最終表現。

在 2019 年期間，所有策略的累積報酬率走勢高度相似，年底時均達到約 1.15 倍的報酬，顯示該階段市場整體多頭氣氛明確，各策略間差異性不顯著。

然而進入 2020 年初後，受新冠疫情爆發影響，股票市場迅速下挫，所有策略的報酬率均出現明顯回落，其中以 B&H 與 MACD 策略的跌幅最為顯著，淨值一度跌破初始報酬。雖然 ML 策略同樣受到市場系統性風險影響，在崩跌初期亦難以完全避險，但其下跌幅度微乎其微。從績效比較表來看，ML 策略的最大回撤僅為 -5.84%，與 B&H (-28.54%) 和 MACD (-24.22%) 的巨大損失形成了鮮明對比，顯示模型在波動環境中能抑制大部分的損失，其良好避險能力讓日後的累積報酬率與其他策略拉開差距。

根據結果，ML 累積報酬率高達 54.72%，明顯優於 B&H 的 46.26% 與 MACD 的 41.96%。此外，其年化波動率僅 10.75%，為三者中最低，顯示其淨值增長曲線更為平穩。綜合風險與報酬，ML 策略的夏普比率達 2.35，不僅是 B&H（1.28）的近兩倍，也高於 MACD（1.35）。

總而言之 ML 策略在實現高報酬的同時，也承擔了最低的風險。本研究證實，此策略在加權指數上成功實現了「漲多跌少」的理想狀態，相較於傳統方法，它提供了更為優異且穩健的風險報酬比，具備高度的實務應用價值。

第五節　機器學習應用於個股之交易績效

為全面驗證機器學習框架的泛用性與穩健性，而非僅適用於大盤指數，本節進一步將完全相同的模型與方法（包含相同的訓練期、測試期、特徵工程與策略規則）應用於台灣市場中三個產業（金融、電子、食品），並於每個產業中分別測試了兩檔具代表性之個股（共計六檔）。

在回測期間，各個個股的股價走勢呈現高波動且強勁反彈的特徵。在 2019 年整體走勢呈現震盪上升趨勢，並在 2020 年初呈現了急劇且大幅度下跌，2020 年底又極速恢復股價，在這樣的股價波動下，部分個股技術指標策略的表現呈現出與加權指數不同的結果，在大部分個股中，RSI 策略的績效表現反而比 MACD 策略與 KD 策略佳，因此，本研究多數個股於技術指標策略部分，使用 RSI 策略作為技術指標策略的代表進行後續分析，少部分使用 MACD 策略。

(一)　電子類股—以鴻海、建準為例

圖 5-5-13 鴻海 RSI、ML 和買進持有策略之累積報酬率比較

圖 5-5-14 建準 RSI、ML 和買進持有策略之累積報酬率比較

表 5-5-8 電子股績效比較

標的	策略	累積報酬率	夏普比率	最大回撤	年化波動率
鴻海	機器學習	46.55%	0.96	−26.19%	23.67%
	RSI	47.76%	1.60	−10.41%	13.34%
	買進持有	22.97%	0.55	−28.56%	25.61%
建準	機器學習	78.05%	1.35	−17.27%	24.34%
	RSI	44.32%	0.83	−33.64%	27.06%
	買進持有	41.44%	0.64	−42.63%	40.69%

如圖 5-5-13、圖 5-5-14 及表 5-5-8 所示，鴻海與建準兩檔電子股於 2019 年至 2020 年間皆呈現高波動走勢，但其趨勢結構明顯不同。鴻海股價在 2019 年間整體呈震盪上行，雖多次出現短期下跌，但皆能迅速反彈；建準股價則呈現明顯單邊上漲格局，波動性雖高但方向性強。

在技術指標策略方面，RSI 策略最終累積報酬率明顯優於 MACD 與 KD。RSI 屬於震盪型指標，專注於捕捉市場短期超買超賣區間，因此在價格快速波動或頻繁反轉的區間市場中，能比 MACD 及 KD 更早且準確地發出買賣訊號。基於此特性，RSI 策略在鴻海及建準兩檔股票中皆作為代表，提供穩定且持續的報酬。

相對地，ML 策略在鴻海股價的震盪走勢中未能準確捕捉轉折點，常於上漲初期提前賣出，或於下跌尚未止穩時過早買進，導致獲利機會受限。其混淆矩陣結果亦顯示交易訊號準確性偏低（買進精確率 23%、賣出召回率 12%），說明模型在獲利與避險判斷上缺乏穩定性，整體績效不如 RSI 策略。

然而，在建準股價的單邊上漲格局下，ML 策略能有效辨識上升趨勢並持續跟隨，最終累積報酬率達 78.05%，明顯優於 B&H 與 RSI 策略，同時展現較高的夏普比率與較低的最大回撤。

整體而言，機器學習策略在電子產業中展現一定的預測與報酬能力，但其績效仍受到股價波動型態與趨勢穩定度的影響。當股價呈現明確單邊走勢（如建準）時，模型能有效掌握趨勢；而在震盪頻繁且反轉多的市場（如鴻海），模型易受雜訊干擾，訊號準確性下降，績效受限。

(二) 金融類股—以中信金、富邦金為例

圖 5-5-15 中信金 RSI、ML 和買進持有策略之累積報酬率比較

圖 5-5-16 富邦金 RSI、ML 和買進持有策略之累積報酬率比較

表 5-5-9 金融股績效比較

標的	策略	累積報酬率	夏普比率	最大回撤	年化波動率
中信金	機器學習	20.02%	1.04	−7.01%	9.30%
	RSI	6.89%	0.27	−23.11%	17.04%
	買進持有	-4.21%	−0.03	−31.13%	19.21%
富邦金	機器學習	-4.36%	−0.07	−24.18 %	16.19%
	RSI	10.50%	0.39	−20.88 %	16.93%
	買進持有	-1.91%	0.05	−26.09 %	19.58%

如圖 5-5-15、圖 5-5-16 及表 5-5-9 所示，大型金融股的價格變動通常較為平穩，波動幅度相對較小，且受宏觀經濟、利率政策、金融監管等因素影響更深，股價走勢更傾向於長期、緩慢的趨勢或窄幅區間盤整，而非電子股常見的急漲急跌。在此背景下，ML 策略在中信金上依然取得了所有策略中的最佳績效，累積報酬率達 20.02%，並且將最大回撤控制在僅-7.01%，雖然報酬率不如加權指數，但其 1.04 的夏普比率遠優於 B&H 和 RSI 策略。這表明 ML 策略在中信金的穩定趨勢中仍能找到規律，並且能有效地避免了 B&H 策略的大幅虧損，

使整體績效由負轉正。

而富邦金的回測結果為最不理想的案例，其 ML 策略不僅未能取得正報酬，反而出現-4.36%的累積虧損。造成此結果的主因在於富邦金股價波動極小，使模型在訓練過程中難以生成足夠的有效特徵與交易訊號，導致測試集不易出現買賣信號，進而無法做出有效決策，使得 ML 策略的學習與判斷能力受到限制，進而影響其報酬表現。

綜合而言，ML 策略在金融股的應用中仍展現出一定的穩健性與風險控制能力，特別是在具中度波動與明確結構的標的（如中信金）上表現優異；然而，當標的波動過小時（如富邦金），模型的預測效能與交易效率將大幅下降，導致其績效不如其他類股。

(三) 食品類股—以卜蜂、泰山為例

圖 5-5-17 卜蜂 RSI、ML 和買進持有策略之累積報酬率比較

圖 5-5-18 泰山 MACD、ML 和買進持有策略之累積報酬率比較

表 5-5-10 食品股績效比較

標的	策略	累積報酬率	夏普比率	最大回撤	年化波動率
卜蜂	機器學習	16.48%	0.58	−17.65 %	15.19%
	RSI	5.94%	0.25	−17.94 %	15.77%
	買進持有	-3.32%	−0.00	−26.27 %	19.70%
泰山	機器學習	55.95%	1.82	-12.37%	13.98%
	MACD	25.49%	0.74	-25.95%	20.57%
	買進持有	33.60%	0.77	-31.54%	26.27%

如圖 5-5-17、圖 5-5-18 及表 5-5-10 所示，食品類股的波動模式與電子股及金融股明顯不同，其價格走勢通常受原物料成本、季節性需求及內需市場因素影響，呈現出中低波動但具周期性變化的特性。在此背景下，ML 策略於卜蜂的回測結果表現出良好的避險價值，該策略成功地將累積報酬率從 B&H 策略的-3.32%提升至 16.48%，其優勢在於 ML 策略規避了 2020 年初的大跌，使策略在股價急跌期間能維持較佳的報酬率，且其最大回撤僅-17.65%遠低於 B&H 策略的-26.27%，隨後於市場反彈階段再度發出買進訊號，最終實現穩定的正向報酬。

相較之下，泰山股價在 2019 年至 2020 年間呈現強勁的單邊上漲趨勢，期間雖伴隨劇烈波動，但整體方向明確。B&H 策略在此階段雖獲利，但其最大回撤高達-31.54%，顯示風險承受度偏高；ML 策略則憑藉對趨勢特徵的精準辨識與進出場時機的掌握，最終達成 55.95%的累積報酬率，並以 1.82 的夏普比率成為所有策略中表現最優異者，此結果說明，泰山股價的波動模式與 ML 模型所學習的特徵結構高度契合，使其能同時兼顧報酬與風險控制。

總之 ML 策略在食品類股的表現展現出良好的風險調整能力與市場適應性。對於波動較低但具突發性風險的個股，模型能發揮避險的效果；而在具明顯趨勢與中度波動的個股，模型則能進一步強化獲利潛力，顯示 ML 策略在不同市場結構下皆具適應彈性與穩定性。

標的	策略	累積報酬率	夏普比率	最大回撤	年化波動率
加權指數	機器學習	54.72%	2.35	-5.84%	0.10%
	MACD	41.96%	1.35	-24.22%	0.08%
	買進持有	46.26%	1.28	-28.54%	0.09%
鴻海	機器學習	46.55%	0.96	−26.19%	23.67%
	RSI	47.76%	1.60	−10.41%	13.34%
	買進持有	22.97%	0.55	−28.56%	25.61%
建準	機器學習	78.05%	1.35	−17.27%	24.34%
	RSI	44.32%	0.83	−33.64%	27.06%
	買進持有	41.44%	0.64	−42.63%	40.69%
中信金	機器學習	20.02%	1.04	−7.01%	9.30%
	RSI	6.89%	0.27	−23.11%	17.04%
	買進持有	-4.21%	−0.03	−31.13%	19.21%
富邦金	機器學習	-4.36%	−0.07	−24.18 %	16.19%
	RSI	10.50%	0.39	−20.88 %	16.93%
	買進持有	-1.91%	0.05	−26.09 %	19.58%

標的	策略	累積報酬率	夏普比率	最大回撤	年化波動率
卜蜂	機器學習	16.48%	0.58	−17.65 %	15.19%
	RSI	5.94%	0.25	−17.94 %	15.77%
	買進持有	-3.32%	−0.00	−26.27 %	19.70%
泰山	機器學習	55.95%	1.82	-12.37%	13.98%
	MACD	25.49%	0.74	-25.95%	20.57%
	買進持有	33.60%	0.77	-31.54%	26.27%

表 5-5-11 個股績效比較

綜上所述，根據上述的實證回測，可觀察到機器學習策略相較於傳統的買進持有與技術指標策略，更能在上漲或下跌的市場中控制風險，減少損失，展現其穩健的績效表現。

第陸章 結論

本研究以台灣股票市場為實證對象，探討機器學習方法應用於股票交易策略之可行性與績效表現。透過將機器學習（ML）策略與傳統技術指標策略（RSI、MACD）以及買進持有（B&H）策略進行比較，研究結果顯示，ML 策略在大多數標的中於累積報酬率、夏普比率及最大回撤等指標上皆優於傳統策略，顯示其具備辨識市場特徵與動態調整交易決策的能力。本章節後續將依序針對各策略的績效差異進行歸納討論，並提出本研究之限制與未來建議。

第一節 研究發現與討論

在技術指標策略方面，RSI 屬於震盪指標，適用於區間盤整或短期反轉市場，因此在高波動的震盪型股票上（如鴻海、建準等），RSI 策略能夠成功捕捉超買超賣的反轉訊號，取得了優於 MACD 和 KD 策略的夏普比率；MACD 則偏向趨勢跟隨，在單邊走勢明確的情況（如加權指數、泰山）下，MACD 可避免過早出場，使策略延長獲利；KD 同樣屬於震盪型，但因計算期間較短，對價格變動極為敏感，容易產生過多交易訊號。雖能快速反應短線轉折，但在高雜訊市場中容易出現「過度交易」現象，增加成本與風險，因此在本研究中未選擇 KD 作為技術指標策略代表。

在機器學習策略方面，高波動與具趨勢結構的市場（如建準、泰山），此策略能充分學習運用技術指標與特徵，獲得高報酬。但仍並非一體適用，尤其在低波動或訊號稀疏的市場（如大型金融股：富邦金），ML 策略因訓練樣本不足導致訊號誤判，整體表現甚至劣於傳統策略。

整體而言，機器學習策略在多數市場情境下皆展現優於傳統技術指標與 B&H 策略的績效。ML 模型具備動態調整能力，可根據市場特徵改變權重與信號敏感度，兼顧報酬與風險控制。然而，策略成效仍

受限於標的波動結構、資料充足性與模型參數設定，顯示策略的成功取決於標的特性的適配性。

第二節　研究限制與未來建議

本研究雖獲致上述結論，然在研究設計上仍有下列幾點限制，茲分述如下：

(一)缺乏模型參數優化：本研究中的機器學習模型有許多內部參數（如 XGBoost 的樹的深度、學習率等）會影響預測效能，但本研究僅採用預設參數，並未找出最佳參數組合。若能進行參數調校，模型有機會提升穩健性及預測能力。

(二)特徵工程維度的侷限：目前模型主要基侷限於價量資料（OHLCV）與三項技術指標。未來研究可嘗試擴展特徵維度，納入如布林通道等不同類型指標、A/D 線等價量資訊，或導入基本面、情緒指標等非結構化資料，提供模型更全面的決策依據。

(三)未考量交易成本：未來可在回測中加入手續費、稅金與滑價等實際交易成本，使各策略的績效評估更貼近真實的市場狀況。

(四)回測週期代表性不足：本研究僅採用 2019-2020 年的回測期間，此區間相對較短，未來可納入更多樣化的市場週期，去驗證模型泛用性。

文獻引用

林奕辰（2020）。基於機器學習的量化投資策略。國立高雄科技大學 財務管理系碩士論文。

林柏年（2020）。以量化交易驗證類股輪動策略之挑選原則與績效評估—以美股為例。國立中央大學 資訊管理學系碩士論文。

周建維（2011）。買賣訊號操作與買進持有策略之投資績效比較－以台灣市場為例。國立宜蘭大學經營管理研究所碩士班論文。

周一華（2022）。技術分析有效性之研究－以 KD、RSI、MACD、MTM 指標為例。國立彰化師範大學財務金融技術學系論文。

翁寬晋（2017）。臺灣股票市場技術分析實證研究－以 MA 指標、KD 指標、RSI 指標、MACD 指標為例。東海大學財務金融學系碩士在職專班論文。

陳姿妤（2023）。運用 XGBoost 演算法進行黃金價格的預測。國立宜蘭大學 應用經濟與管理學系應用經濟學碩士論文。

黃中義（2020）。XGBoost 投資策略實證分析。國立中山大學 財務管理系碩士論文。

劉俞含（2018）。XGBoost 模型、隨機森林模型、彈性網模型於股價指數趨勢之預測—以台灣、日本、美國為例。國立中山大學 財務管理學系碩士論文。

劉順富（2019）。用 XGBOOST 演算法預測台灣指數期貨。國立雲林科技大學 財務金融系碩士論文。

劉家宏（2023）。XGBoost 模型在小型台灣指數期貨價格預測之實證分析。國立中山大學 財務管理學系碩士論文。

劉妤真（2024）。機器學習與股票報酬。私立逢甲大學 財務金融學系碩士論文。

賴韋勝（2019）。使用機器學習預測基金績效。私立輔仁大學 金融與國際企業學系碩士論文。

附錄

```
--- ML 模型分類報告 ---
Classification Report:
              precision    recall  f1-score   support

           0       0.48      0.68      0.56       243
           1       0.23      0.18      0.20       137
           2       0.46      0.12      0.20        97

    accuracy                           0.42       477
   macro avg       0.39      0.33      0.32       477
weighted avg       0.41      0.42      0.38       477
```

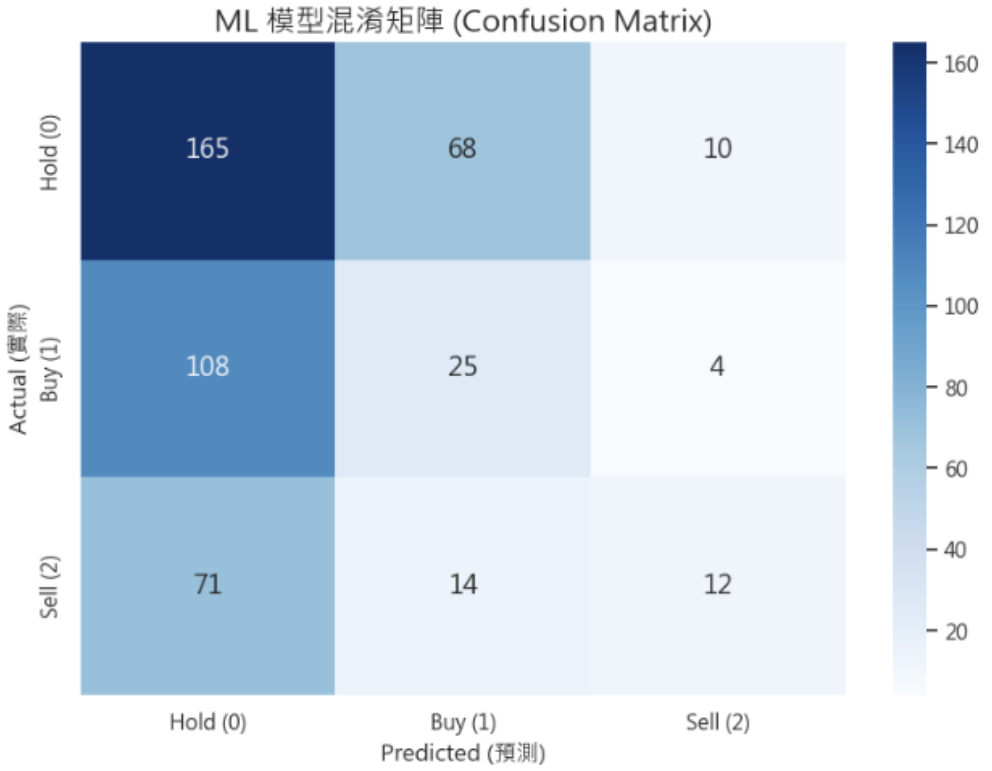

圖 7-1-19 鴻海之模組分析

圖 7-1-20 鴻海技術指標之累積報酬率

圖 7-1-21 鴻海之 RSI 交易策略訊號

圖 7-1-22 鴻海之 ML 交易策略訊號

```
--- ML 模型分類報告 ---
Classification Report:
              precision    recall  f1-score   support

           0       0.33      0.34      0.33       169
           1       0.33      0.30      0.31       162
           2       0.41      0.44      0.42       146

    accuracy                           0.35       477
   macro avg       0.35      0.36      0.36       477
weighted avg       0.35      0.35      0.35       477
```

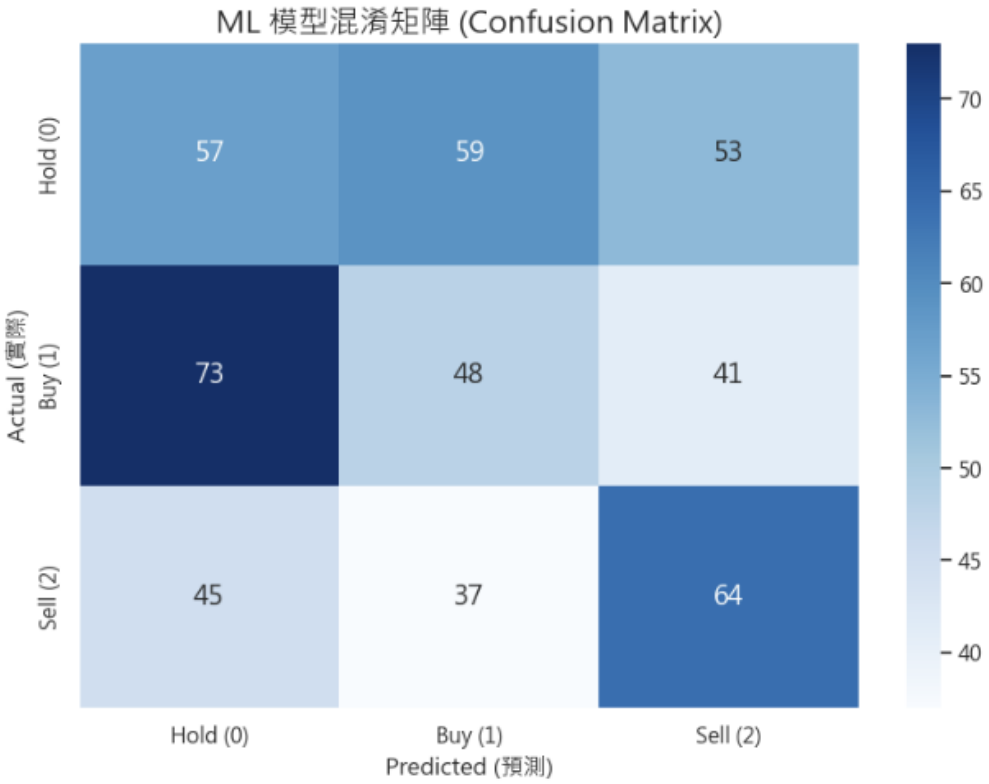

圖 7-1-23 建準之模組分析

圖 7-1-24 建準技術指標之累積報酬率

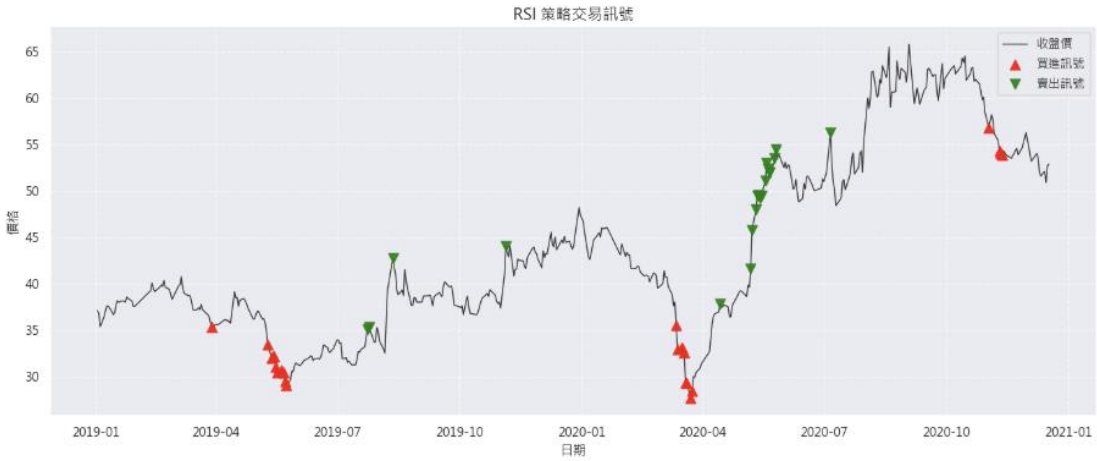

圖 7-1-25 建準之 RSI 交易策略訊號

圖 7-1-26 建準之 ML 交易策略訊號

```
--- ML 模型分類報告 ---
Classification Report:
              precision    recall  f1-score   support

           0       0.76      0.91      0.83       350
           1       0.77      0.14      0.23        74
           2       0.13      0.11      0.12        53

    accuracy                           0.70       477
   macro avg       0.55      0.39      0.39       477
weighted avg       0.69      0.70      0.66       477
```

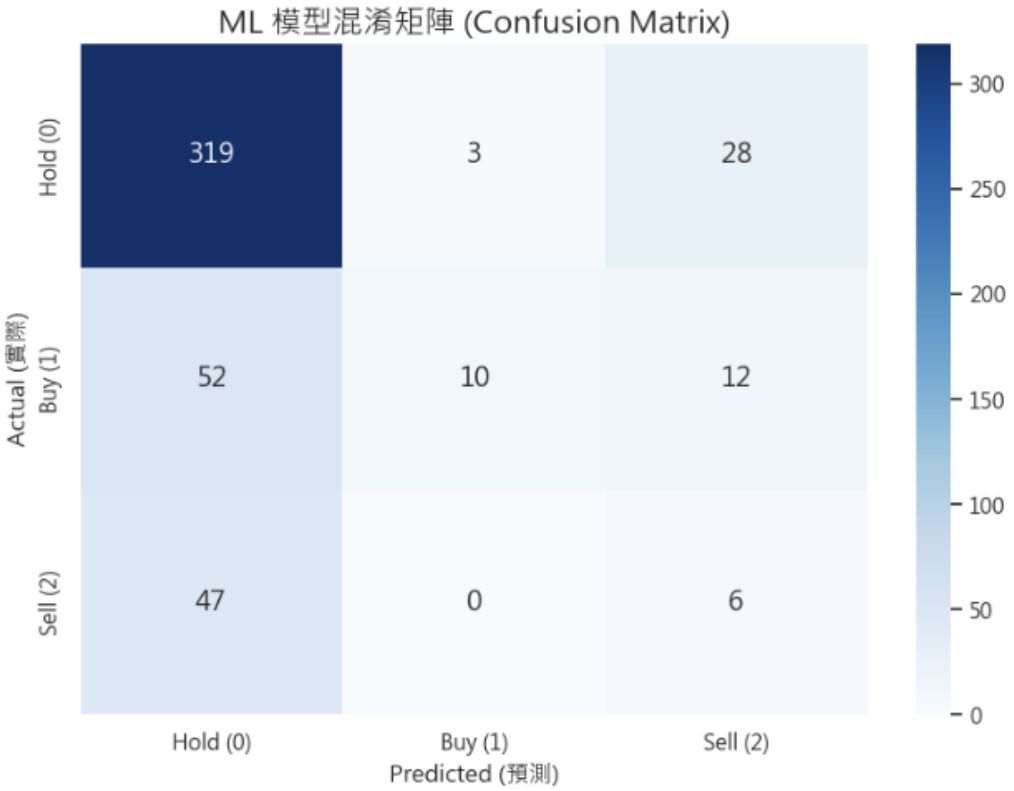

圖 7-1-27 中信金之模組分析

圖 7-1-28 中信金技術指標之累積報酬率

圖 7-1-29 中信金之 RSI 交易策略訊號

圖 7-1-30 中信金之 ML 交易策略訊號

```
--- ML 模型分類報告 ---
Classification Report:
              precision    recall  f1-score   support

           0       0.69      0.93      0.79       324
           1       0.38      0.11      0.17        84
           2       0.00      0.00      0.00        69

    accuracy                           0.65       477
   macro avg       0.35      0.35      0.32       477
weighted avg       0.53      0.65      0.57       477
```

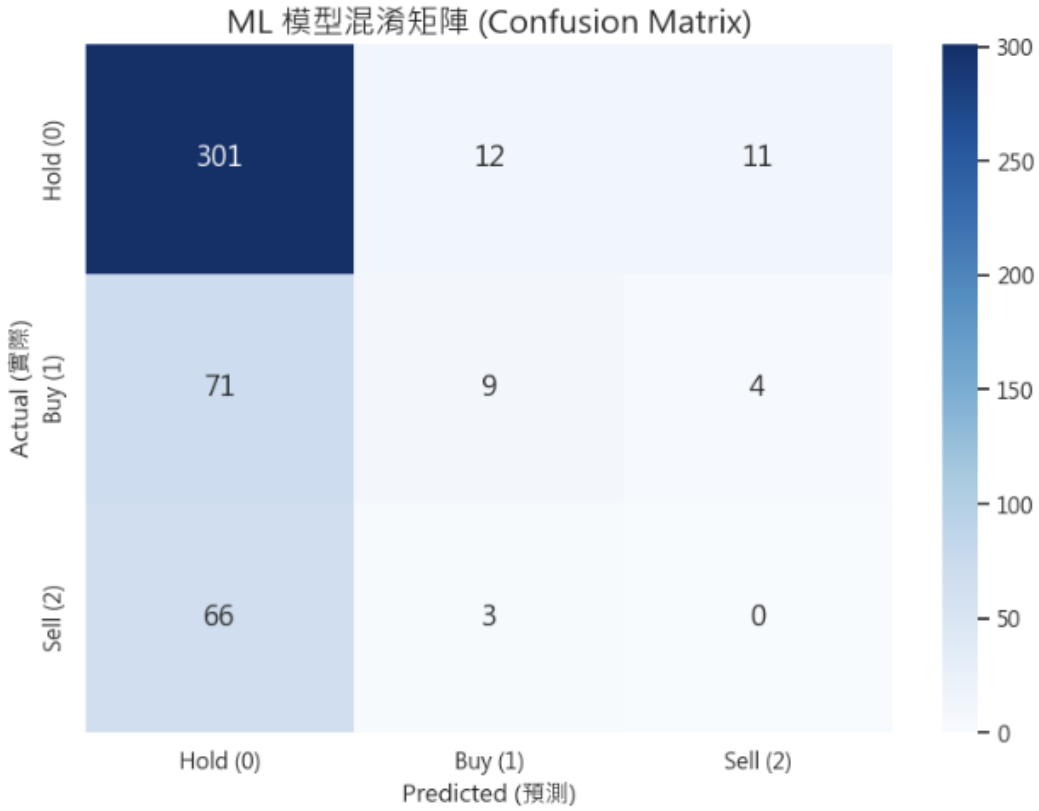

圖 7-1-31 富邦金之模組分析

圖 7-1-32 富邦金技術指標之累積報酬率

圖 7-1-33 富邦金之 RSI 交易策略訊號

圖 7-1-34 富邦金之 ML 交易策略訊號

```
--- ML 模型分類報告 ---
Classification Report:
              precision    recall  f1-score   support

           0       0.67      0.87      0.75       314
           1       0.48      0.26      0.33        78
           2       0.07      0.02      0.04        85

    accuracy                           0.62       477
   macro avg       0.41      0.38      0.37       477
weighted avg       0.53      0.62      0.56       477
```

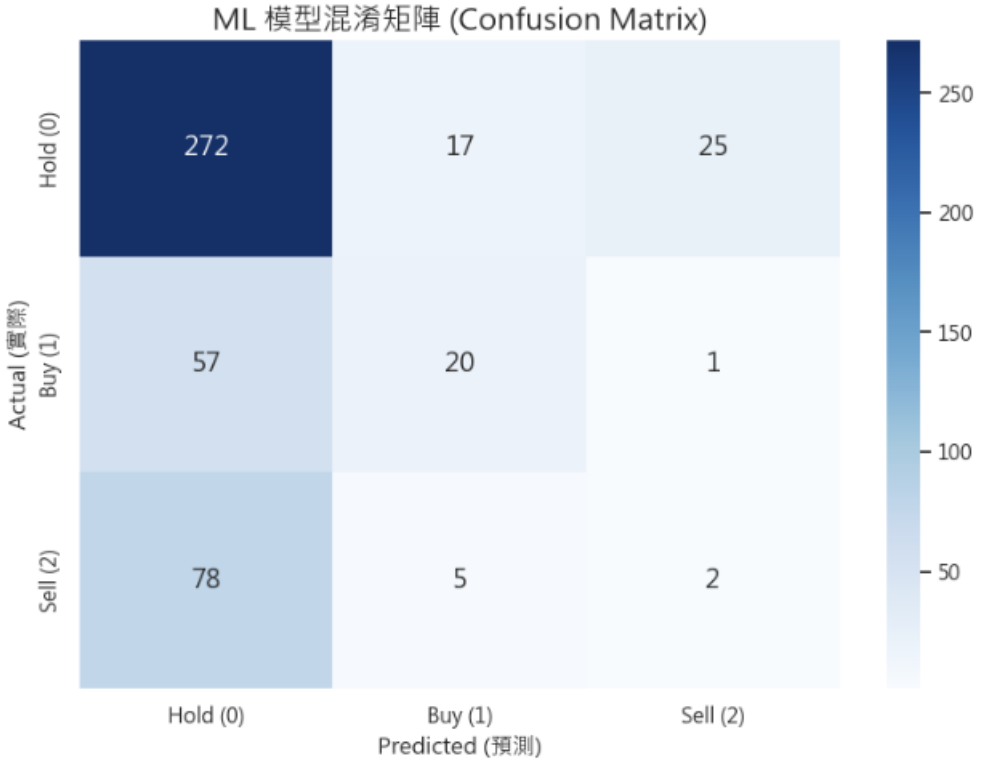

圖 7-1-35 卜蜂之模組分析

圖 7-1-36 卜蜂技術指標之累積報酬率

圖 7-1-37 卜蜂之 RSI 交易策略訊號

圖 7-1-38 卜蜂之 ML 交易策略訊號

```
--- ML 模型分類報告 ---
Classification Report:
              precision    recall  f1-score   support

           0       0.55      0.67      0.61       260
           1       0.28      0.14      0.19       137
           2       0.31      0.36      0.33        80

    accuracy                           0.47       477
   macro avg       0.38      0.39      0.38       477
weighted avg       0.44      0.47      0.44       477
```

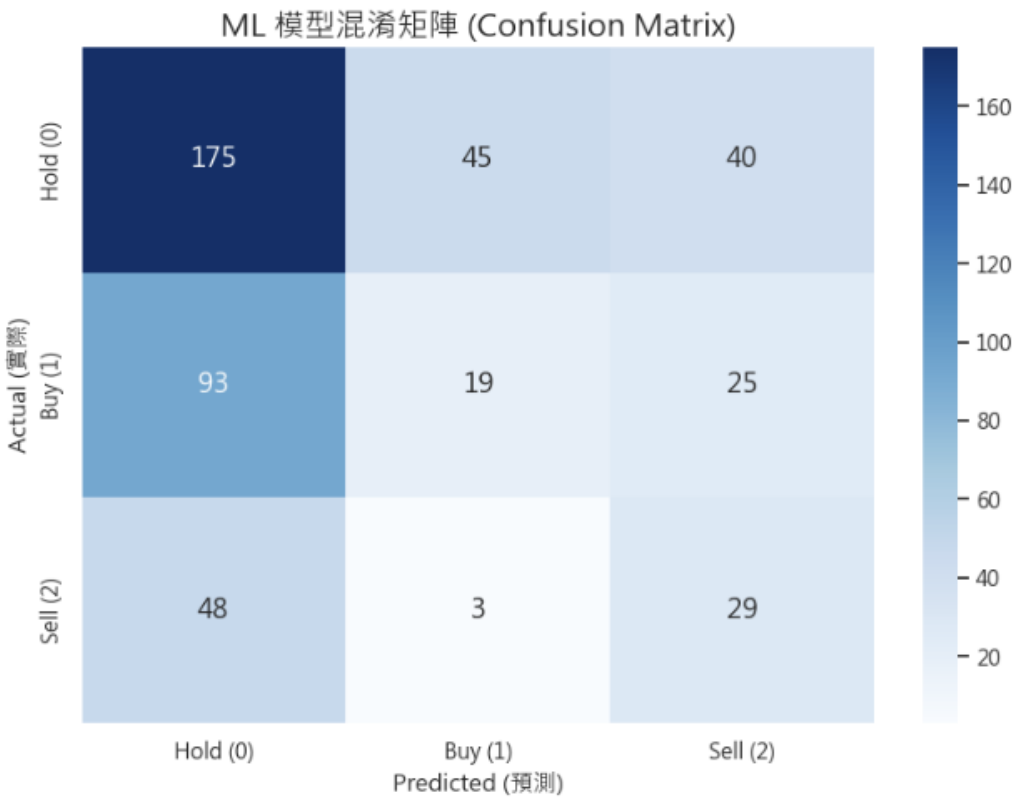

圖 7-1-39 泰山之模組分析

圖 7-1-40 泰山技術指標之累積報酬率

圖 7-1-41 泰山之 MACD 交易策略訊號

圖 7-1-42 泰山之 ML 交易策略訊號

圖 7-1-43 完整程式碼 QR code